

Concours ANP — Cadre Data Scientist

Sujet d'examen blanc n° 1

Direction Stratégie et Développement — Service Intelligence Économique

Durée : 3 heures — Aucun document autorisé

Consignes. Le sujet comporte six parties indépendantes. Traitez-les dans l'ordre de votre choix. La clarté de la rédaction, la rigueur du raisonnement et la capacité à **vulgariser** sont évaluées au même titre que l'exactitude technique. Barème indicatif sur **100 points**.

Partie A — ANP et environnement portuaire (15 points)

- A.1** Citez trois missions de l'**Agence Nationale des Ports** et précisez son **statut juridique**.
- A.2** Qu'est-ce que la **loi 15-02** ? Expliquez en quoi elle a transformé l'organisation du système portuaire marocain (séparation des rôles, régulation, concurrence).
- A.3** Définissez cinq des termes suivants : *terminal, quai, tirant d'eau, manutention, transbordement, hinterland, chaîne logistique, dragage*.
- A.4** Le Service Intelligence Économique doit produire des **insights stratégiques** pour la Direction. Donnez trois exemples de décisions portuaires qu'un travail de data science pourrait éclairer.
- A.5** Quel est l'intérêt de la **digitalisation des ports** du point de vue de la performance et de la compétitivité ?

Partie B — Statistiques et probabilités (15 points)

- B.1** Définissez **moyenne, médiane, variance et écart-type**. Dans quel cas la médiane est-elle préférable à la moyenne ?
- B.2** Expliquez la différence entre **covariance** et **corrélation**. Une corrélation forte implique-t-elle un lien de causalité ? Justifiez.
- B.3** On mesure le temps d'attente (en heures) de 7 navires :

4, 6, 5, 9, 30, 7, 6

Calculez la moyenne et la médiane. Commentez l'écart entre les deux.

- B.4** Énoncez le **théorème de Bayes**. Un système de détection d'anomalies sur des déclarations douanières a une sensibilité de 95 % et un taux de faux positifs de 8 %. Les anomalies réelles représentent 2 % des déclarations. Quelle est la probabilité qu'une déclaration signalée soit réellement anormale ?
- B.5** Qu'est-ce qu'une **distribution normale** ? Citez deux grandeurs portuaires dont la distribution n'est probablement pas normale et expliquez pourquoi.

Partie C — Data Science et Machine Learning (30 points)

- C.1** Distinguez **apprentissage supervisé** et **non supervisé**. Donnez pour chacun un cas d'usage à l'ANP.

- C.2** Quelle est la différence entre **classification**, **régression** et **clustering** ? Rattachez chacune à un des verbes de la fiche de poste : *classification*, *segmentation*, *scoring*, *prévision*.
- C.3** Expliquez l'**overfitting** : qu'est-ce que c'est, comment le **détecter**, comment le **réduire** (citez trois leviers).
- C.4** À partir d'une **matrice de confusion**, définissez **TP**, **TN**, **FP**, **FN**, puis **Accuracy**, **Precision**, **Recall** et **F1-score**. Pour un modèle qui prédit quels conteneurs inspecter physiquement, faut-il privilégier la précision ou le recall ? Discutez.
- C.5** Expliquez le principe de la **validation croisée** (*k-fold*). À quoi sert-elle ?
- C.6** Comparez **Random Forest** et **régression logistique** : donnez deux avantages de chacun. Dans quelle situation choisiriez-vous Random Forest ?
- C.7** Décrivez en quelques lignes le principe de **XGBoost**, de **K-Means** et de la **PCA**.
- C.8** Un jeu de données de fraude est **déséquilibré** (1 % de cas positifs). Citez trois techniques pour traiter ce problème et expliquez **SMOTE**.

Partie D — Python et SQL

(20 points)

- D.1 — Python / Pandas.** On dispose d'un DataFrame `escales` avec les colonnes : `navire`, `port`, `date_arrivee`, `date_depart`, `tonnage`, `type_marchandise`.
- D.1.1** Affichez les 5 premières lignes et un résumé statistique des colonnes numériques.
- D.1.2** Créez une colonne `duree_escale` (en heures) à partir des deux dates.
- D.1.3** Supprimez les lignes où `tonnage` est manquant, puis remplacez les `tonnage` nuls restants par la médiane du port.
- D.1.4** Donnez le tonnage total et la durée d'escale moyenne **par port** et **par type de marchandise**.
- D.1.5** Triez les ports par tonnage total décroissant et affichez le top 3.
- D.2 — SQL.** Schéma : `navires(id, nom, pavillon, capacite_evp)`; `escales(id, navire_id, port, arrivee, depart, evp_manutentionnes)`; `ports(nom, region)`.
- D.2.1** Nombre d'escales et total d'EVP manutentionnés **par port**, pour l'année 2025, triés par EVP décroissants.
- D.2.2** Ports ayant manutentionné plus de 100 000 EVP sur la période (**GROUP BY + HAVING**).
- D.2.3** Pour chaque région, le port le plus actif en EVP (**window function** ou sous-requête corrélée).
- D.2.4** Liste des navires n'ayant fait **aucune** escale en 2025 (**LEFT JOIN** ou **NOT EXISTS**).
- D.2.5** À l'aide d'une CTE et d'un **CASE WHEN**, classez chaque escale en *courte* (<12h), *normale* (12–48h) ou *longue* (>48h) et comptez chaque catégorie par port.

Partie E — Big Data, BI et veille

(10 points)

- E.1** Décrivez le rôle de **HDFS** et de **MapReduce** dans l'écosystème Hadoop. Qu'apporte **Spark** par rapport à MapReduce ?
- E.2** Dans **Kafka**, définissez : **Topic**, **Partition**, **Offset**, **Consumer Group**.
- E.3** Proposez une **architecture bout en bout** pour ingérer en continu les positions AIS des navires et alimenter un tableau de bord (sources → ingestion → traitement → stockage → restitution).
- E.4** Différence entre **ETL** et **ELT**. Entre **Data Warehouse** et **Data Mart**.
- E.5** Expliquez le **schéma en étoile** : table de faits vs table de dimension, granularité. Citez deux opérations **OLAP**.
- E.6** Vous devez organiser une **veille concurrentielle** sur les ports de la façade atlantique africaine. Quels critères utilisez-vous pour sélectionner vos sources d'information ? Comment **recoupez-vous** l'information ?

Partie F — Cas pratique

(10 points)

L'ANP souhaite prédire le temps d'attente des navires en rade avant accostage, afin d'optimiser la planification des postes à quai.

Rédigez une démarche data science structurée couvrant au minimum :

1. les données à collecter et leurs sources (internes / externes) ;
2. le nettoyage et la préparation ;
3. l'analyse exploratoire (EDA) ;
4. le **feature engineering** (variables pertinentes : météo, marée, type de navire, taux d'occupation des quais, saisonnalité...) ;
5. le découpage **train** / **test** et la stratégie de validation ;
6. le choix du **type de modèle** et deux algorithmes candidats ;
7. les **métriques d'évaluation** adaptées ;
8. le **déploiement**, le **monitoring** et la restitution via un **tableau de bord** pour les équipes d'exploitation.

Précisez enfin un **risque éthique ou biais** possible et comment le maîtriser.