

Concours ANP — Cadre Data Scientist

Sujet d'examen blanc n° 2 — orientation *veille et études économiques*

Direction Stratégie et Développement — Service Intelligence Économique

Durée : 3 heures — Aucun document autorisé

Consignes. Six parties indépendantes. Ce sujet insiste sur la **mission de veille économique et concurrentielle** et sur la **réalisation d'études**, sans négliger le socle technique. Barème indicatif sur **100 points**.

Partie A — ANP, régulation et contexte (15 points)

- A.1** Rappelez le **statut juridique** de l'ANP et le rôle d'une **autorité portuaire** (régulation, contrôle, sécurité).
- A.2** Quel est le **périmètre** d'intervention de l'ANP ? Citez l'exception connue.
- A.3** Selon l'**article 33 de la loi 15-02**, énumérez quatre missions de l'Agence.
- A.4** Le poste est rattaché au **Service Intelligence Économique**. Définissez, avec vos mots, ce qu'est l'intelligence économique et distinguez **veille**, **analyse** et **influence**.
- A.5** Donnez trois **sujets d'intérêt sectoriel** sur lesquels une veille stratégique portuaire serait pertinente aujourd'hui.

Partie B — Statistiques appliquées à une étude (15 points)

- B.1** Différence entre **probabilité** et **probabilité conditionnelle**. Donnez un exemple portuaire de chaque.
- B.2** Vous comparez le trafic conteneurs moyen mensuel de deux ports sur 24 mois. Quelles précautions statistiques prenez-vous avant de conclure qu'un port « performe mieux » que l'autre ?
- B.3** Définissez le **coefficient de corrélation** et donnez son intervalle de valeurs. Interprétez $r = -0,85$.
- B.4** On observe que le trafic d'un port et le PIB régional ont une corrélation de 0,9. Peut-on utiliser le PIB pour **prévoir** le trafic ? Quels sont les pièges (variable de confusion, rétro-causalité, tendance commune) ?
- B.5** Qu'est-ce qu'un **échantillon représentatif** ? Pourquoi est-ce crucial pour une enquête auprès des usagers portuaires ?

Partie C — Modélisation pour la prévision économique (25 points)

- C.1** La fiche de poste demande de « développer des modèles statistiques et de machine learning pour anticiper les évolutions du marché ». Distinguez un modèle **explicatif** d'un modèle **prédictif**.
- C.2** Qu'est-ce qu'une **série temporelle** ? Citez ses composantes (tendance, saisonnalité, résidu) et deux difficultés propres à la prévision de séries temporelles.

- C.3 Expliquez la différence entre **régression linéaire** et **régression logistique** : nature de la cible, sortie du modèle, cas d'usage.
- C.4 Décrivez le principe d'un **arbre de décision** puis d'une **forêt aléatoire**. Qu'apporte l'**ensemble learning** ?
- C.5 Vous construisez un **score de risque** de retard pour les chaînes d'approvisionnement des importateurs. Quelle métrique d'évaluation choisissez-vous et pourquoi ? Qu'est-ce que la **ROC-AUC** ?
- C.6 Qu'est-ce que le **data leakage** ? Donnez un exemple où une variable « fuite » l'information du futur dans un modèle de prévision de trafic.
- C.7 Citez les étapes de **preprocessing** pour préparer des données économiques hétérogènes : valeurs manquantes, valeurs aberrantes, **encodage**, **normalisation** / **standardisation**.

Partie D — Python et SQL pour l'analyse (20 points)

- D.1 — Python / Pandas.** DataFrame `trafic` : colonnes `port`, `mois` (format AAAA-MM), `evp_import`, `evp_export`, `tonnage_vrac`.
- D.1.1 Chargez le fichier `trafic.csv` et inspectez types et valeurs manquantes.
 - D.1.2 Ajoutez une colonne `evp_total` et une colonne `annee`.
 - D.1.3 Calculez le **trafic EVP total par an et par port**, puis le **taux de croissance annuel** par port.
 - D.1.4 Identifiez, pour chaque port, le mois de trafic EVP le plus élevé.
 - D.1.5 Fusionnez (`merge`) avec un DataFrame `regions(port, region)` et donnez le trafic total par région.
- D.2 — SQL.** Schéma : `etudes(id, titre, commanditaire, date_livraison, statut)`; `indicateurs(id, etude_id, nom, valeur, unite, annee)`; `sources(id, etude_id, libelle, type, fiabilite)`.
- D.2.1 Nombre d'études **par statut** et **par année de livraison**.
 - D.2.2 Études livrées en retard : `date_livraison` postérieure au 2025-06-30 et `statut` = 'en cours'.
 - D.2.3 Pour chaque étude, la **moyenne de fiabilité** de ses sources (`JOIN + GROUP BY`), triée croissante.
 - D.2.4 Études s'appuyant **uniquement** sur des sources de type 'externe' (sous-requête ou `NOT EXISTS`).
 - D.2.5 À l'aide d'une **window function**, classez les indicateurs d'une même étude par valeur décroissante et ne gardez que les 3 premiers (`ROW_NUMBER / RANK`).

Partie E — Veille, sources et outils BI (15 points)

- E.1 Pour organiser une veille, on évalue les sources selon **fiabilité**, **richesse**, **fraîcheur**, **accessibilité**, **coût**. Définissez chaque critère et donnez un exemple de source forte / faible sur ce critère.
- E.2 Comment **recouper** et **valider** une information stratégique avant de la transmettre à la Direction ?
- E.3 Décrivez un **processus de veille** en cycle : besoin, collecte, traitement, analyse, diffusion.
- E.4 Qu'est-ce qu'un **cube OLAP** ? Distinguez **dimensions** et **mesures**. Citez les opérations *drill-down*, *roll-up*, *slice*, *dice*, *pivot*.
- E.5 La fiche cite Power BI, Tableau, SAS, SPSS. Ce sont des **implémentations**. Quels sont les **concepts transversaux** de la BI qu'un data scientist doit maîtriser indépendamment de l'outil ?

E.6 Qu'est-ce qu'un **KPI**? Proposez quatre KPI pertinents pour un **tableau de bord stratégique portuaire**.

Partie F — Cas pratique : étude de marché **(10 points)**

La Direction demande une étude : « Quels sont les risques et opportunités de concurrence pour les ports marocains à l'horizon 2030, face au développement des ports concurrents de la région ? »

Rédigez votre **méthodologie d'étude** :

1. cadrage du besoin et questions clés ;
2. identification et hiérarchisation des **sources** (institutionnelles, sectorielles, données ouvertes, presse spécialisée) ;
3. indicateurs à collecter et à modéliser (trafic, capacités, tarifs, délais, connectivité maritime. . .) ;
4. méthode d'analyse (benchmark, analyse de tendances, scénarios, éventuellement un modèle prédictif de parts de trafic) ;
5. livrables et **restitution** à la Direction ;
6. limites de l'étude et niveau de confiance des conclusions.