

Concours ANP — Cadre Data Scientist

Sujet d'examen blanc n° 3 — orientation *données, pipelines et restitution*

Direction Stratégie et Développement — Service Intelligence Économique

Durée : 3 heures — Aucun document autorisé

Consignes. Six parties indépendantes. Ce sujet met l'accent sur la **collecte**, la **structuration** et le **nettoyage des données** (SQL/NoSQL, ETL, intégration multi-sources), le **Big Data** et la **visualisation**. Barème indicatif sur **100 points**.

Partie A — ANP et enjeux data (12 points)

- A.1** En une phrase chacune : qu'est-ce que l'**ANP**, quelle est sa **loi fondatrice**, quel est son **statut**.
- A.2** Citez trois missions de l'ANP (article 33 de la **loi 15-02**).
- A.3** Sur quelles **catégories de données** un data scientist peut-il travailler dans un port ? Donnez-en au moins six (opérationnelles, logistiques, économiques, environnementales...).
- A.4** Citez cinq termes du **vocabulaire portuaire** et définissez-en trois.
- A.5** Pourquoi la **qualité des données** est-elle un enjeu stratégique pour la prise de décision de la Direction ?

Partie B — Statistiques (13 points)

- B.1** Définissez **variance** et **écart-type**. Pourquoi utilise-t-on souvent l'écart-type plutôt que la variance ?
- B.2** Qu'est-ce qu'une **valeur aberrante** (outlier) ? Citez deux méthodes pour la détecter (écart interquartile, z-score).
- B.3** Un capteur de tirant d'eau renvoie des mesures dont 3 % sont clairement fausses (valeurs négatives ou > 40 m). Quelles stratégies de traitement proposez-vous, et laquelle retenez-vous ?
- B.4** Expliquez la **probabilité conditionnelle** avec l'exemple : « probabilité qu'un conteneur soit contrôlé sachant qu'il vient d'un port à risque ».
- B.5** Qu'est-ce que la **normalisation** et la **standardisation** d'une variable ? Quand chacune est-elle préférable ?

Partie C — Machine Learning (25 points)

- C.1** Différence **IA** / **Machine Learning** / **Deep Learning**.
- C.2** Expliquez le découpage **training** / **validation** / **test** et le rôle de chaque ensemble.
- C.3** Qu'est-ce que le **feature engineering** et la **feature selection** ? Pourquoi sont-ils souvent plus déterminants que le choix de l'algorithme ?
- C.4** Décrivez **K-Means**. Comment choisir le nombre de clusters k ? Donnez un cas d'usage : **segmentation** des usagers portuaires.

- C.5 Décrivez la **PCA** et son intérêt sur un jeu de données à forte dimension.
- C.6 Comparez **Random Forest** et **XGBoost** (principe, forces, points d'attention).
- C.7 Qu'est-ce que le **hyperparameter tuning** ? Citez deux méthodes (grid search, random search).
- C.8 Un modèle de classification a une **Accuracy de 98 %** sur un problème où 98 % des cas sont négatifs. Le modèle est-il bon ? Quelles métriques regardez-vous à la place ?

Partie D — Python, SQL et NoSQL (25 points)

- D.1 — Python / Pandas.** DataFrame capteurs : id_capteur, port, horodatage, grandeur, valeur, unite.
- D.1.1 Chargez capteurs.csv, convertissez horodatage en type date, trie par capteur et par temps.
 - D.1.2 Supprimez les **doublons** exacts et les lignes dont valeur est manquante.
 - D.1.3 Pour chaque port et chaque grandeur, calculez moyenne, min, max et écart-type des valeur.
 - D.1.4 Filtrez (loc) les mesures de grandeur = 'houle' supérieures à un seuil de 2,5 m et comptez-les par port.
 - D.1.5 Ré-échantillonnez les données à un pas **horaire** (moyenne) pour un capteur donné.
- D.2 — SQL.** Schéma : operations(id, port, terminal, navire_id, debut, fin, evp, tonnes); navires(id, nom, type, capacite_evp); terminaux(nom, port, nb_postes, operateur).
- D.2.1 Débit moyen (EVP par heure) **par terminal**, sur 2025.
 - D.2.2 Terminaux dont le débit moyen dépasse la moyenne globale (sous-requête).
 - D.2.3 Pour chaque port, le **top 2** des navires par tonnage manutentionné (**window function**).
 - D.2.4 Navires de type = 'porte-conteneurs' n'ayant jamais opéré sur un terminal de l'opérateur 'X' (LEFT JOIN / NOT EXISTS).
 - D.2.5 Avec une CTE et CASE WHEN, catégorisez chaque opération par taux de remplissage (evp / capacite_evp) en *faible*, *moyen*, *élevé*, et donnez la répartition par port.
- D.3 — NoSQL / ETL (questions courtes).**
- D.3.1 Donnez deux différences entre une base **relationnelle** et une base **NoSQL documentaire**. Quand privilégier NoSQL ?
 - D.3.2 Vous devez intégrer quotidiennement des fichiers de trois systèmes (format CSV, API JSON, export SGBD). Décrivez les étapes d'un **pipeline ETL** et deux contrôles de qualité à mettre en place.

Partie E — Big Data et architecture (15 points)

- E.1 Rôle de **HDFS**, **MapReduce**, **Spark**. Qu'est-ce qu'un **RDD** et un **DataFrame** Spark ?
- E.2 À quoi sert **Spark Streaming** ? Donnez un cas portuaire.
- E.3 **Kafka** : expliquez **Producer**, **Consumer**, **Topic**, **Partition**, **Offset**, **Replication**.
- E.4 Dessinez (schéma + légende) une **architecture bout en bout** : *sources* → *Kafka* → *Spark* → *Data Lake* → *Data Warehouse* → *ML / BI*. Précisez le rôle de chaque étage.
- E.5 Différence **Data Lake** / **Data Warehouse**. Différence **ETL** / **ELT**.

Partie F — Cas pratique : tableau de bord (10 points)

La Direction veut un tableau de bord stratégique de la performance portuaire, actualisé quotidiennement, à partir de données provenant de plusieurs ports et de plusieurs systèmes.

Proposez :

1. les **sources** et la fréquence d'actualisation ;
2. le **pipeline de données** (ingestion, nettoyage, modélisation en **schéma en étoile** : table de faits, dimensions, granularité) ;
3. les **indicateurs** / **KPI** à afficher (au moins six) et la façon de les visualiser sans induire en erreur ;
4. la gestion des **données manquantes ou en retard** d'un port ;
5. les **contrôles de qualité** et la traçabilité ;
6. un point d'**éthique** : quelles données ne doivent pas figurer, ou doivent être agrégées, et pourquoi.