

Fiche de révision — Machine Learning

Concours ANP — Cadre Data Scientist

1 Concepts ML de base

1.1 AI vs ML vs Deep Learning

- **Intelligence Artificielle (AI)** : le domaine le plus large — toute technique qui permet à une machine d'imiter un comportement humain intelligent (raisonnement, perception, décision). Inclut des règles écrites à la main (systèmes experts), pas forcément de l'apprentissage.
- **Machine Learning (ML)** : sous-ensemble de l'AI où la machine *apprend* un modèle à partir de données, au lieu de suivre des règles écrites explicitement. On lui montre des exemples, elle en déduit un pattern généralisable.
- **Deep Learning (DL)** : sous-ensemble du ML basé sur des réseaux de neurones à plusieurs couches (*deep* = profond). Excelle quand il y a beaucoup de données non structurées (images, texte, son) et peu de features déjà préparées à la main.

Hiérarchie à retenir : $AI \supset ML \supset \text{Deep Learning}$.

Idée clé à savoir formuler : le ML classique (Random Forest, XGBoost...) reste souvent préférable sur des données tabulaires (comme des données économiques ou portuaires) car plus interprétable et moins gourmand en données/calcul que le Deep Learning.

1.2 Apprentissage supervisé vs non supervisé

- **Supervised learning (apprentissage supervisé)** : on dispose de données déjà étiquetées, c'est-à-dire qu'on connaît la réponse attendue (*target*) pour chaque exemple historique. Le modèle apprend la relation entre les features et le target pour prédire ce target sur de nouvelles données.
 - Exemple : prédire si un navire sera en retard (oui/non) à partir de son historique.
- **Unsupervised learning (apprentissage non supervisé)** : les données n'ont *pas* de target connu. Le modèle cherche uniquement une structure ou des regroupements cachés dans les données.
 - Exemple : regrouper des navires ou des clients par profil similaire sans savoir à l'avance quels groupes existent.

1.3 Classification vs régression vs clustering

- **Classification** (supervisé) : le target est une *catégorie* discrète (ex. retard / pas de retard, fraude / pas fraude).
- **Régression** (supervisé) : le target est une valeur *continue* (ex. temps d'attente en heures, montant d'une facture).
- **Clustering** (non supervisé) : regrouper des observations similaires entre elles, sans target prédéfini (ex. segmentation de clients ou de navires).

1.4 Training, testing, validation

- **Training set (entraînement)** : les données sur lesquelles le modèle apprend ses paramètres.
- **Validation set** : sert à régler les hyperparamètres et comparer plusieurs modèles *sans* toucher aux données de test, pour éviter de biaiser l'évaluation finale.
- **Test set** : données jamais vues par le modèle pendant l'entraînement, utilisées une seule fois à la fin pour mesurer la performance réelle attendue en production.

Pourquoi séparer les trois : si on évalue le modèle sur les données qui ont servi à l'entraîner, on surestime sa performance réelle (voir *overfitting* plus loin).

1.5 Features et target

- **Features (variables explicatives)** : les colonnes/informations d'entrée utilisées par le modèle pour faire une prédiction (ex. tirant d'eau du navire, type de marchandise, heure d'arrivée).
- **Target (variable cible)** : ce qu'on cherche à prédire (ex. le temps d'attente du navire).

Question type à savoir répondre à l'oral :

« Quelle différence entre classification et régression, avec un exemple portuaire ? »

2 Algorithmes (principe, sans les maths profondes)

2.1 Linear Regression

2.2 Logistic Regression

2.3 Decision Tree

2.4 Random Forest

2.5 XGBoost

2.6 K-Means

2.7 PCA

2.8 Question type

3 Évaluation ML

3.1 Classification — Confusion Matrix

3.2 Classification — Métriques

3.3 Régression — Métriques

3.4 Questions types

4 ML avancé (Jour 3)

4.1 Preprocessing

4.2 Feature engineering et feature selection

4.3 Data leakage

4.4 Imbalanced dataset et SMOTE

4.5 Cross-validation

4.6 Hyperparameter tuning

4.7 Gradient Boosting et Ensemble Learning

4.8 Questions ouvertes