

# Fiche de révision — Machine Learning

Concours ANP — Cadre Data Scientist

## Table des matières

|          |                                                      |           |
|----------|------------------------------------------------------|-----------|
| <b>1</b> | <b>Concepts ML de base</b>                           | <b>2</b>  |
| 1.1      | AI vs ML vs Deep Learning . . . . .                  | 2         |
| 1.2      | Apprentissage supervisé vs non supervisé . . . . .   | 2         |
| 1.3      | Classification vs régression vs clustering . . . . . | 2         |
| 1.4      | Training, testing, validation . . . . .              | 2         |
| 1.5      | Features et target . . . . .                         | 3         |
| <b>2</b> | <b>Algorithmes</b>                                   | <b>3</b>  |
| 2.1      | Linear Regression . . . . .                          | 3         |
| 2.2      | Logistic Regression . . . . .                        | 4         |
| 2.3      | Decision Tree . . . . .                              | 5         |
| 2.4      | Random Forest . . . . .                              | 7         |
| 2.5      | XGBoost . . . . .                                    | 8         |
| 2.6      | K-Means . . . . .                                    | 9         |
| <b>3</b> | <b>Évaluation ML</b>                                 | <b>10</b> |
| 3.1      | Classification — Confusion Matrix . . . . .          | 10        |
| 3.2      | Classification — Métriques . . . . .                 | 10        |
| 3.3      | Régression — Métriques . . . . .                     | 11        |
| 3.4      | Questions types . . . . .                            | 11        |
| <b>4</b> | <b>ML avancé (Jour 3)</b>                            | <b>12</b> |
| 4.1      | Preprocessing . . . . .                              | 12        |
| 4.2      | Feature engineering et feature selection . . . . .   | 12        |
| 4.3      | Data leakage . . . . .                               | 12        |
| 4.4      | Imbalanced dataset et SMOTE . . . . .                | 12        |
| 4.5      | Cross-validation . . . . .                           | 12        |
| 4.6      | Hyperparameter tuning . . . . .                      | 12        |
| 4.7      | Gradient Boosting et Ensemble Learning . . . . .     | 12        |
| 4.8      | Questions ouvertes . . . . .                         | 12        |

# 1 Concepts ML de base

## 1.1 AI vs ML vs Deep Learning

- **Intelligence Artificielle (AI)** : le domaine le plus large — toute technique qui permet à une machine d'imiter un comportement humain intelligent (raisonnement, perception, décision). Inclut des règles écrites à la main (systèmes experts), pas forcément de l'apprentissage.
- **Machine Learning (ML)** : sous-ensemble de l'AI où la machine *apprend* un modèle à partir de données, au lieu de suivre des règles écrites explicitement. On lui montre des exemples, elle en déduit un pattern généralisable.
- **Deep Learning (DL)** : sous-ensemble du ML basé sur des réseaux de neurones à plusieurs couches (*deep* = profond). Excelle quand il y a beaucoup de données non structurées (images, texte, son) et peu de features déjà préparées à la main.

**Hiérarchie à retenir** :  $AI \supset ML \supset \text{Deep Learning}$ .

**Idée clé à savoir formuler** : le ML classique (Random Forest, XGBoost...) reste souvent préférable sur des données tabulaires (comme des données économiques ou portuaires) car plus interprétable et moins gourmand en données/calcul que le Deep Learning.

## 1.2 Apprentissage supervisé vs non supervisé

- **Supervised learning (apprentissage supervisé)** : on dispose de données déjà étiquetées, c'est-à-dire qu'on connaît la réponse attendue (*target*) pour chaque exemple historique. Le modèle apprend la relation entre les features et le target pour prédire ce target sur de nouvelles données.
  - Exemple : prédire si un navire sera en retard (oui/non) à partir de son historique.
- **Unsupervised learning (apprentissage non supervisé)** : les données n'ont *pas* de target connu. Le modèle cherche uniquement une structure ou des regroupements cachés dans les données.
  - Exemple : regrouper des navires ou des clients par profil similaire sans savoir à l'avance quels groupes existent.

## 1.3 Classification vs régression vs clustering

- **Classification** (supervisé) : le target est une *catégorie* discrète (ex. retard / pas de retard, fraude / pas fraude).
- **Régression** (supervisé) : le target est une valeur *continue* (ex. temps d'attente en heures, montant d'une facture).
- **Clustering** (non supervisé) : regrouper des observations similaires entre elles, sans target prédéfini (ex. segmentation de clients ou de navires).

## 1.4 Training, testing, validation

- **Training set (entraînement)** : les données sur lesquelles le modèle apprend ses paramètres.
- **Validation set** : sert à régler les hyperparamètres et comparer plusieurs modèles *sans* toucher aux données de test, pour éviter de biaiser l'évaluation finale.
- **Test set** : données jamais vues par le modèle pendant l'entraînement, utilisées une seule fois à la fin pour mesurer la performance réelle attendue en production.

**Pourquoi séparer les trois** : si on évalue le modèle sur les données qui ont servi à l'entraîner, on surestime sa performance réelle (voir *overfitting* plus loin).

## 1.5 Features et target

- **Features (variables explicatives)** : les colonnes/informations d'entrée utilisées par le modèle pour faire une prédiction (ex. tirant d'eau du navire, type de marchandise, heure d'arrivée).
- **Target (variable cible)** : ce qu'on cherche à prédire (ex. le temps d'attente du navire).

*Question type à savoir répondre à l'oral :*

« Quelle différence entre classification et régression, avec un exemple portuaire ? »

## 2 Algorithmes

### 2.1 Linear Regression

**Principe** : trouve la droite (ou l'hyperplan, avec plusieurs features) qui passe "au plus près" de tous les points observés, en minimisant la somme des écarts au carré entre la valeur prédite et la valeur réelle. Le modèle prédit une valeur *continue* comme une combinaison linéaire pondérée des features :  $y = \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_0$ .

#### Formalisation mathématique — du simple au général

**Étape 1 — l'équation avec 2 features seulement.** Prenons le cas le plus simple, avec deux features  $x_1$  et  $x_2$  :

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

Exemple concret : prédire le temps d'attente d'un navire (en heures) avec  $x_1$  = tirant d'eau et  $x_2$  = nombre de conteneurs à décharger. Une fois le modèle entraîné,  $\theta_0, \theta_1, \theta_2$  sont simplement **3 nombres fixes** (par exemple  $\theta_0 = 2, \theta_1 = 0.5, \theta_2 = 0.01$ ).

**Étape 2 — les  $\theta_j$  sont constants pour toutes les lignes.** Une fois appris,  $\theta_0, \theta_1, \theta_2$  ne changent *plus* : ce sont les mêmes 3 nombres réutilisés pour prédire n'importe quel nouveau navire. Ce qui change d'une ligne (d'un navire) à l'autre, ce sont uniquement les valeurs  $x_1, x_2$  — jamais les  $\theta$  :

| Navire | $x_1$ (tirant d'eau) | $x_2$ (conteneurs) | $\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2$ |
|--------|----------------------|--------------------|----------------------------------------------------|
| A      | 8                    | 200                | $2 + 0.5(8) + 0.01(200) = 8$                       |
| B      | 12                   | 500                | $2 + 0.5(12) + 0.01(500) = 13$                     |

Même  $\theta_0, \theta_1, \theta_2$  dans les deux lignes — seuls  $x_1, x_2$  changent d'un navire à l'autre. C'est cette propriété (paramètres partagés par toutes les observations) qui permet au modèle de *généraliser* à de nouveaux navires jamais vus.

**Étape 3 — généralisation à  $p$  features.** Pour une observation  $i$  avec un vecteur de features  $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ , le modèle prédit :

$$\hat{y}_i = \theta_0 + \theta_1 x_{i1} + \theta_2 x_{i2} + \dots + \theta_p x_{ip} = \boldsymbol{\theta}^\top \mathbf{x}_i$$

Le **double indice**  $x_{ij}$  (valeur de la feature  $j$  pour l'observation  $i$ ) distingue bien les deux rôles :  $i$  indexe la *ligne* (le navire),  $j$  indexe la *feature* (tirant d'eau, nombre de conteneurs, ...). En revanche  $\theta_j$  n'a **qu'un seul indice** : il ne dépend que de la feature  $j$ , jamais de la ligne  $i$  — exactement comme dans le tableau ci-dessus.

*Remarque de notation* :  $\boldsymbol{\theta}$  et  $\boldsymbol{\beta}$  désignent le même objet (le vecteur de coefficients) —  $\boldsymbol{\theta}$  est la notation la plus courante côté Machine Learning,  $\boldsymbol{\beta}$  vient de la tradition statistique.

**On minimise uniquement par rapport à  $\theta$ .** Les données d'entraînement  $x_i, y_i$  sont *fixes* (ce sont des constantes du problème une fois le dataset choisi) — seuls les  $\theta_j$  sont ajustés pour rendre l'erreur  $J(\theta)$  la plus petite possible :

$$\hat{\theta} = \arg \min_{\theta} J(\theta)$$

C'est pour cela que la mise à jour du gradient (plus bas) s'écrit séparément pour chaque  $\theta_j$ , avec sa propre dérivée partielle  $\frac{\partial J}{\partial \theta_j}$  : elle mesure combien  $J$  changerait si l'on bougeait légèrement *seulement* ce coefficient, tous les autres  $\theta$  et toutes les données restant fixes. En pratique, tous les  $\theta_j$  sont mis à jour simultanément à chaque itération.

**Fonction de coût (Ordinary Least Squares).** On cherche les paramètres qui minimisent la moyenne des carrés des résidus (*Mean Squared Error*) sur les  $m$  observations d'entraînement :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

**Pourquoi le carré ?** Le carré permet :

- d'éviter que les erreurs positives et négatives s'annulent ;
- de pénaliser fortement les grandes erreurs ;
- d'obtenir une fonction facilement optimisable par dérivation.

Le facteur 2 (qui apparaît dans certaines écritures de  $J$ , par ex.  $\frac{1}{2m} \sum (\hat{y}_i - y_i)^2$ ) est principalement une convention mathématique qui facilite la dérivée : il s'annule avec le 2 provenant de la dérivée du carré.

**Pourquoi  $m$  ?** On veut calculer une moyenne des erreurs — diviser par  $m$  (le nombre d'observations) rend le coût comparable d'un dataset à l'autre, indépendamment du nombre d'exemples.

**Lien avec Gradient Descent.** On utilise souvent la descente de gradient pour trouver les paramètres  $\theta$  qui minimisent cette fonction :

$$\theta_j \leftarrow \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

où  $\alpha$  est le *learning rate*.

**Hypothèses statistiques du modèle** (utile si on te pousse sur la théorie) : linéarité de la relation, indépendance des résidus, homoscedasticité (variance des résidus constante), normalité des résidus, absence de multicollinéarité forte.

- **Type de problème** : régression (target continu).
- **Cas d'usage** : prédire le temps d'attente d'un navire en heures, prédire un montant, une quantité, un prix.
- **Limites** :
  - Suppose une relation *linéaire* entre features et target — capte mal les relations complexes/non linéaires.
  - Sensible aux *outliers* (valeurs extrêmes qui tirent la droite).
  - Sensible à la *colinéarité* entre features (deux features très corrélées entre elles perturbent l'interprétation des coefficients).
- **Avantage clé à mentionner** : très interprétable — chaque coefficient  $\theta_j$  indique l'effet direct et quantifiable de la feature  $x_j$  sur le target, ce qui est précieux pour justifier une décision auprès d'une Direction.

## 2.2 Logistic Regression

**Principe** : malgré son nom, c'est un modèle de *classification*, pas de régression. Il prédit une *probabilité* (entre 0 et 1) d'appartenir à une classe, en appliquant une fonction sigmoïde à une combinaison linéaire des features. On fixe ensuite un seuil (souvent 0,5) pour décider de la classe finale : si probabilité  $\geq 0,5 \rightarrow$  classe 1, sinon classe 0.

## Formalisation mathématique

**Fonction sigmoïde (logistique).** On combine linéairement les features comme en régression linéaire,  $z_i = \beta^\top \mathbf{x}_i + \beta_0$ , puis on écrase ce score réel dans l'intervalle  $[0, 1]$  via :

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad \Rightarrow \quad P(y_i = 1 \mid \mathbf{x}_i) = \hat{p}_i = \sigma(z_i) = \frac{1}{1 + e^{-(\beta^\top \mathbf{x}_i + \beta_0)}}$$

**Log-odds (logit).** La régression logistique modélise en fait le logarithme du rapport de cotes comme une fonction linéaire des features, ce qui justifie le nom "logistic" :

$$\text{logit}(\hat{p}_i) = \ln \left( \frac{\hat{p}_i}{1 - \hat{p}_i} \right) = \beta^\top \mathbf{x}_i + \beta_0$$

Un coefficient  $\beta_j$  s'interprète donc comme l'effet de  $x_j$  sur le *log-odds* :  $e^{\beta_j}$  est le facteur multiplicatif appliqué au rapport de cotes quand  $x_j$  augmente de 1 unité.

**Fonction de coût (Binary Cross-Entropy / Log-Loss).** On ne peut pas utiliser la somme des carrés (non convexe ici) : on maximise la vraisemblance des observations, ce qui revient à minimiser la *log-loss* sur les  $n$  observations ( $y_i \in \{0, 1\}$ ) :

$$J(\beta, \beta_0) = -\frac{1}{n} \sum_{i=1}^n \left[ y_i \ln(\hat{p}_i) + (1 - y_i) \ln(1 - \hat{p}_i) \right]$$

Cette fonction est convexe en  $\beta$ , ce qui garantit un minimum global unique.

**Optimisation.** Contrairement à la régression linéaire, il n'y a pas de solution analytique fermée : on optimise  $J$  par descente de gradient (ou variantes comme Newton-Raphson / IRLS) :

$$\beta_j \leftarrow \beta_j - \alpha \frac{\partial J}{\partial \beta_j} \quad \text{avec} \quad \frac{\partial J}{\partial \beta_j} = \frac{1}{n} \sum_{i=1}^n x_{ij} (\hat{p}_i - y_i)$$

Remarque : cette dérivée a exactement la même forme que pour la régression linéaire (prédiction — réel, pondéré par la feature) — c'est une propriété élégante commune à tous les modèles linéaires généralisés (GLM) avec une fonction de lien canonique.

- **Type de problème** : classification (le plus souvent binaire ; extensible au multi-classe).
- **Cas d'usage** : prédire si un navire sera en retard (oui/non), détecter une anomalie ou une fraude, scoring d'un dossier (accepté/refusé).
- **Limites** :
  - Suppose que les classes sont *linéairement séparables* (une frontière de décision simple)
  - performe mal sur des frontières complexes.
  - Sensible aux features non standardisées et aux outliers.
  - Moins performante que Random Forest/XGBoost sur des données avec beaucoup d'interactions entre variables.
- **Avantage clé à mentionner** : tout comme la régression linéaire, elle reste interprétable (coefficients = effet sur le log-odds) et donne directement une probabilité utile pour prioriser des cas (ex. classer les navires par risque de retard décroissant), pas seulement une étiquette binaire.


**Point à ne pas confondre à l'oral** : Linear Regression prédit un *nombre continu* ; Logistic Regression prédit une *probabilité*/catégorie. Les deux sont des modèles linéaires simples, souvent utilisés comme *baseline* avant de tester des modèles plus complexes (Random Forest, XGBoost).

## 2.3 Decision Tree

**Étape 1 — l'intuition.** Un arbre de décision pose une suite de questions simples de type "la feature  $x_j$  est-elle  $\leq$  un seuil  $s$  ?" et découpe les données en deux groupes à chaque question,

jusqu'à obtenir des groupes finaux (*feuilles*) les plus "purs" possible (majoritairement une seule classe, ou une valeur de target homogène).

*Exemple portuaire* : "tirant d'eau > 10 m ?" → si oui, "nombre de conteneurs > 300 ?" → ... jusqu'à la feuille qui donne la prédiction (ex. "retard probable" / "pas de retard").



**Étape 2 — comment choisir la meilleure question ?** À chaque nœud, l'arbre teste toutes les features et tous les seuils possibles, et choisit celui qui rend les groupes résultants les plus purs. Pour mesurer l'impureté d'un groupe, deux critères principaux :

**Indice de Gini** (classification), pour un nœud contenant  $K$  classes de proportions  $p_1, \dots, p_K$  :

$$\text{Gini} = 1 - \sum_{k=1}^K p_k^2$$

Gini = 0 si le nœud est parfaitement pur (une seule classe) ; Gini est maximal quand les classes sont mélangées à parts égales.

**Entropie** (alternative à Gini, issue de la théorie de l'information) :

$$\text{Entropie} = - \sum_{k=1}^K p_k \log_2(p_k)$$

**Gain d'information.** On choisit la question (feature + seuil) qui *maximise la réduction d'impureté* entre le nœud parent et ses deux enfants (gauche  $G$ , droit  $D$ ), pondérée par la taille de chaque enfant :

$$\text{Gain} = \text{Impureté}_{\text{parent}} - \left( \frac{n_G}{n} \text{Impureté}_G + \frac{n_D}{n} \text{Impureté}_D \right)$$

où  $n$  est le nombre d'observations au nœud parent,  $n_G$  et  $n_D$  le nombre d'observations envoyées respectivement à gauche et à droite.

**Cas de la régression** : au lieu de Gini/entropie, on minimise la variance (ou la MSE) des valeurs de target dans chaque groupe — même logique de la fonction de coût que pour Linear Regression, appliquée localement à chaque nœud.

**Arrêt de la construction.** L'arbre s'arrête de grandir quand une condition est atteinte : profondeur maximale (**max\_depth**), nombre minimal d'observations par feuille (**min\_samples\_leaf**), ou gain d'information devenu négligeable.

- **Type de problème** : classification et régression.
- **Cas d'usage** : règles de décision explicables (ex. scoring d'un dossier avec des critères métier lisibles), segmentation de navires par profil de risque.
- **Limites** :
  - **Overfitting très facile** si l'arbre est laissé libre de grandir (il peut isoler chaque observation dans sa propre feuille).
  - **Instable** : une petite variation dans les données d'entraînement peut produire un arbre très différent (forte variance).
  - Frontières de décision "en escalier" (perpendiculaires aux axes), donc moins naturelles que celles d'un modèle linéaire pour des relations lisses.
- **Avantage clé à mentionner** : très interprétable et visualisable (on peut littéralement dessiner l'arbre et le montrer à un métier non technique) ; ne nécessite ni scaling ni normalisation des features.

## 2.4 Random Forest

**Étape 1 — le problème que ça résout.** Un seul Decision Tree a une forte variance (instable, sensible à l'overfitting). L'idée du Random Forest : au lieu d'un seul arbre, en construire *beaucoup* (ex. 100, 500) et faire la **moyenne** de leurs prédictions (régression) ou un **vote majoritaire** (classification). Des erreurs individuelles d'arbres différents ont tendance à s'annuler, ce qui réduit la variance globale sans trop augmenter le biais.

**Étape 2 — comment rendre les arbres différents entre eux ?** Si tous les arbres étaient construits sur exactement les mêmes données avec les mêmes règles, ils seraient identiques et la moyenne n'apporterait rien. Random Forest introduit deux sources d'aléa (technique dite du *bagging* = *Bootstrap Aggregating*) :

- **Bootstrap sur les lignes** : chaque arbre est entraîné sur un échantillon tiré *avec remise* (même taille  $m$  que le dataset original, mais certaines lignes apparaissent plusieurs fois, d'autres pas du tout).
- **Sélection aléatoire de features** : à chaque nœud, l'arbre ne considère qu'un sous-ensemble aléatoire des features (souvent  $\sqrt{p}$  pour la classification,  $p/3$  pour la régression, avec  $p$  = nombre total de features) au lieu de toutes les tester — cela décorrèle davantage les arbres entre eux.

**Formalisation de l'agrégation.** Pour  $T$  arbres entraînés  $f_1, \dots, f_T$  :

$$\hat{y}_{\text{régression}} = \frac{1}{T} \sum_{t=1}^T f_t(\mathbf{x}) \qquad \hat{y}_{\text{classification}} = \text{mode}(f_1(\mathbf{x}), \dots, f_T(\mathbf{x}))$$

c'est-à-dire la moyenne des  $T$  prédictions numériques, ou la classe la plus votée parmi les  $T$  arbres.

**Pourquoi ça marche (intuition de la réduction de variance).** Si chaque arbre a une variance  $\sigma^2$  et que les erreurs des arbres sont peu corrélées, la variance de la moyenne de  $T$  arbres tend vers  $\sigma^2/T$  — d'où l'intérêt de maximiser  $T$  (dans une limite raisonnable) et de décorréliser les arbres (bootstrap + sélection aléatoire de features).

**Feature importance** (bonus utile à mentionner) : Random Forest fournit naturellement un score d'importance par feature, en mesurant de combien chaque feature réduit l'impureté (Gini/variance) en moyenne sur tous les arbres et tous les nœuds où elle est utilisée — utile pour expliquer un modèle à une Direction.

- **Type de problème** : classification et régression.
- **Cas d'usage** : la plupart des problèmes tabulaires "par défaut" (scoring, prévision, détection d'anomalie) — bon compromis performance/simplicité de mise en œuvre.
- **Limites** :
  - Moins interprétable qu'un seul Decision Tree (on ne peut plus "dessiner" la décision)
    - on s'appuie sur la feature importance en remplacement.
  - Plus coûteux en mémoire/temps de calcul qu'un modèle linéaire ou qu'un seul arbre (il faut stocker et faire tourner  $T$  arbres).
  - Peut rester moins performant que du Gradient Boosting/XGBoost sur des données très structurées, car les arbres sont construits indépendamment (pas de correction séquentielle des erreurs).
- **Avantage clé à mentionner** : robuste par défaut (peu de tuning nécessaire), gère bien les valeurs manquantes/outliers, réduit fortement l'overfitting par rapport à un arbre seul
  - c'est souvent le premier modèle "sérieux" à essayer après une baseline linéaire.

**Question type à savoir répondre à l'oral** : « *Pourquoi choisir Random Forest plutôt que Logistic Regression ?* » → Random Forest capte des relations non linéaires et des interactions complexes entre features sans les spécifier à la main, gère nativement les variables catégorielles et les valeurs manquantes, et est moins sensible aux outliers — au prix d'une interprétabilité directe des coefficients (compensée par la feature importance). Logistic Regression reste préférable quand

l'interprétabilité fine (impact exact et signé de chaque variable) est exigée, ou quand le volume de données est trop faible pour justifier un modèle complexe.

## 2.5 XGBoost

**Étape 1 — boosting vs bagging.** Random Forest construit ses  $T$  arbres *indépendamment* (en parallèle) puis moyenne leurs prédictions — c'est le *bagging*. Le *boosting* (dont XGBoost est la version la plus utilisée en pratique) construit ses arbres *séquentiellement* : chaque nouvel arbre est entraîné pour corriger les erreurs laissées par l'ensemble des arbres précédents, au lieu de repartir de zéro sur un échantillon aléatoire.

|                          | Bagging (Random Forest)     | Boosting (XGBoost)                       |
|--------------------------|-----------------------------|------------------------------------------|
| Construction des arbres  | indépendante (parallèle)    | séquentielle                             |
| Objectif de chaque arbre | re-voter sur un échantillon | corriger l'erreur des précédents         |
| Effet recherché          | réduire la <i>variance</i>  | réduire le <i>biais</i> (et la variance) |

**Étape 2 — l'intuition du boosting.** On part d'une première prédiction simple  $\hat{y}^{(0)}$  (par exemple la moyenne du target). À chaque étape  $t$ , on calcule le *résidu* (l'erreur restante) et on entraîne un nouvel arbre  $f_t$  pour prédire *ce résidu*, pas directement  $y$  :

$$\hat{y}^{(t)} = \hat{y}^{(t-1)} + \eta \cdot f_t(\mathbf{x})$$

où  $\eta$  (*learning rate*, souvent petit : 0.01 à 0.3) contrôle la contribution de chaque nouvel arbre — avancer par petits pas évite de sur-corriger et de tomber dans l'overfitting.

*Exemple portuaire* : un premier arbre prédit un temps d'attente moyen grossier ; le deuxième arbre apprend spécifiquement sur quels navires ce premier arbre s'est le plus trompé, et corrige dans cette direction ; ainsi de suite.

**Étape 3 — fonction objectif de XGBoost.** XGBoost formalise l'ajout de chaque arbre comme la minimisation d'une fonction objectif qui combine une fonction de perte  $l$  (ex. MSE pour la régression, log-loss pour la classification) et un terme de régularisation  $\Omega$  qui pénalise la complexité de l'arbre :

$$\text{Obj}^{(t)} = \sum_{i=1}^m l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t) \quad \text{avec} \quad \Omega(f_t) = \gamma T_{\text{feuilles}} + \frac{1}{2} \lambda \sum_k w_k^2$$

où  $T_{\text{feuilles}}$  est le nombre de feuilles de l'arbre  $f_t$ ,  $w_k$  le poids (valeur de prédiction) de la feuille  $k$ , et  $\gamma, \lambda$  des hyperparamètres de régularisation. C'est ce terme  $\Omega$  (absent du Gradient Boosting classique) qui donne au "X" (*eXtreme*) de XGBoost sa robustesse à l'overfitting.

**Pourquoi la régularisation compte ici** : sans elle, le boosting — qui cherche activement à corriger *chaque* erreur résiduelle — finirait par apprendre le bruit des données d'entraînement.  $\Omega$  force les arbres à rester petits (peu de feuilles) et les poids de feuille modérés (via  $\lambda$ ), un peu comme une régularisation L2 sur les coefficients d'une régression linéaire.

- **Type de problème** : classification et régression (et ranking).
- **Cas d'usage** : quasiment la référence actuelle sur données tabulaires en compétition/production — scoring fin, prévision, détection de fraude, quand on veut pousser la performance au-delà d'un Random Forest.
- **Limites** :
  - Plus d'hyperparamètres à régler (`learning_rate`, `max_depth`, `n_estimators`,  $\gamma$ ,  $\lambda$ ...)
  - nécessite du tuning (grid search / cross-validation) pour être performant.
  - Entraînement séquentiel donc moins parallélisable que Random Forest (bien que XGBoost parallélise la construction *interne* de chaque arbre).



- Plus sensible au bruit/outliers que Random Forest si mal régularisé, puisqu’il cherche justement à corriger les erreurs résiduelles.
- **Avantage clé à mentionner** : très souvent la meilleure performance brute sur données tabulaires structurées, régularisation intégrée qui limite l’overfitting, gère nativement les valeurs manquantes (l’arbre apprend la meilleure direction par défaut pour les valeurs absentes).

## 2.6 K-Means

**Étape 1 — l’intuition.** K-Means est un algorithme de *clustering* (non supervisé) : il regroupe  $m$  observations en  $K$  groupes (*clusters*), sans connaître à l’avance les vraies étiquettes. L’idée : chaque cluster est résumé par un point central appelé *centroïde*, et chaque observation est assignée au cluster dont le centroïde est le plus proche.

*Exemple portuaire* : regrouper des navires en  $K = 3$  profils (petits navires rapides, porte-conteneurs moyens, tankers volumineux) à partir de features comme le tonnage et le temps de manutention — sans savoir à l’avance combien de profils existent réellement ni comment les nommer.

**Étape 2 — l’algorithme, pas à pas.** Pour un nombre de clusters  $K$  fixé à l’avance :

1. **Initialisation** : choisir  $K$  centroïdes de départ (souvent  $K$  points tirés au hasard parmi les observations).
2. **Assignment** : affecter chaque observation  $\mathbf{x}_i$  au centroïde  $\mu_k$  le plus proche (distance euclidienne la plus courante) :

$$c_i = \arg \min_{k \in \{1, \dots, K\}} \|\mathbf{x}_i - \mu_k\|^2$$

3. **Mise à jour** : recalculer chaque centroïde comme la *moyenne* des observations qui lui sont assignées :

$$\mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i$$

4. **Répéter** les étapes 2 et 3 jusqu’à convergence (les assignments ne changent plus, ou nombre maximal d’itérations atteint).

**Étape 3 — que minimise K-Means ?** L’algorithme minimise l’inertie intra-cluster (*Within-Cluster Sum of Squares*), c’est-à-dire la somme des distances au carré entre chaque point et le centroïde de son cluster :

$$J = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mu_k\|^2$$

Chaque étape (assignment puis mise à jour) fait strictement décroître (ou stagner)  $J$  — l’algorithme converge donc toujours, mais pas nécessairement vers le minimum *global* (il peut rester bloqué dans un minimum local selon l’initialisation).

**Comment choisir  $K$  ?**  $K$  est un hyperparamètre fixé *avant* l’entraînement, pas appris par l’algorithme. Deux méthodes classiques :

- **Méthode du coude (elbow method)** : tracer  $J$  en fonction de  $K$  ;  $J$  décroît toujours quand  $K$  augmente, mais on choisit le  $K$  où la décroissance ralentit nettement (le "coude" de la courbe).
- **Score de silhouette** : mesure à quel point chaque point est proche de son propre cluster comparé aux autres clusters (valeur entre  $-1$  et  $1$ , plus c’est proche de  $1$ , mieux les clusters sont séparés).

**Limite d’initialisation et parade.** Comme le résultat dépend de l’initialisation, on relance généralement K-Means plusieurs fois avec des initialisations différentes et on garde la solution avec le  $J$  le plus bas (c’est ce que fait **k-means++** par défaut dans scikit-learn, qui choisit intelligemment les centroïdes de départ pour accélérer la convergence).

- **Type de problème** : clustering (non supervisé).
- **Cas d'usage** : segmentation de clients/navires/opérateurs portuaires par profil, détection de groupes homogènes pour adapter une politique tarifaire ou une allocation de ressources.
- **Limites** :
  - Il faut choisir  $K$  à l'avance (pas toujours évident métier).
  - Suppose des clusters de forme *sphérique* et de taille comparable (distance euclidienne)
    - performe mal sur des clusters de formes complexes ou de densités très différentes.
  - Sensible aux *outliers* (un point extrême peut fortement déplacer un centroïde) et à l'*échelle des features* (nécessite un scaling préalable, contrairement aux arbres).
- **Avantage clé à mentionner** : simple, rapide, facile à interpréter (chaque cluster est résumé par son centroïde) — bon premier réflexe pour explorer une structure cachée dans des données non étiquetées avant d'aller plus loin.

### 3 Évaluation ML

#### 3.1 Classification — Confusion Matrix

**Principe.** Pour un problème de classification binaire, on compare la classe *prédite* par le modèle à la classe *réelle* pour chaque observation du test set. Il n'existe que 4 cas possibles, résumés dans la matrice de confusion :

|        |         | Réel    |         |
|--------|---------|---------|---------|
|        |         | Positif | Négatif |
| Prédit | Positif | TP      | FP      |
|        | Négatif | FN      | TN      |

- **TP (Vrai Positif)** : le modèle prédit positif, et c'est effectivement positif. *Ex. : le modèle prédit "navire en retard", et il l'est vraiment.*
- **TN (Vrai Négatif)** : le modèle prédit négatif, et c'est effectivement négatif. *Ex. : le modèle prédit "pas de retard", et il n'y en a effectivement pas.*
- **FP (Faux Positif)** — "fausse alerte" : le modèle prédit positif, mais c'est en réalité négatif. *Ex. : le modèle annonce un retard qui n'arrive pas.*
- **FN (Faux Négatif)** — "occasion manquée" : le modèle prédit négatif, mais c'est en réalité positif. *Ex. : le modèle ne voit rien venir, mais le navire est bien en retard.*

*Astuce pour ne jamais confondre à l'oral* : le 2<sup>e</sup> mot (Positif/Négatif) est toujours ce que le modèle a *prédit* ; le 1<sup>er</sup> mot (Vrai/Faux) indique si cette prédiction était *correcte* ou non.

#### 3.2 Classification — Métriques

**Accuracy** — proportion de prédictions correctes sur l'ensemble des prédictions :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

*Limite majeure* : trompeuse sur un dataset déséquilibré. Si 95% des navires ne sont pas en retard, un modèle qui prédit toujours "pas de retard" obtient 95% d'accuracy sans être utile.

**Precision** — parmi les cas prédits positifs, combien le sont vraiment (mesure la fiabilité des alertes) :

$$\text{Precision} = \frac{TP}{TP + FP}$$

**Recall (rappel/sensibilité)** — parmi les cas réellement positifs, combien le modèle en a détecté (mesure la capacité à ne rien manquer) :

$$\text{Recall} = \frac{TP}{TP + FN}$$

**F1-score** — moyenne harmonique de Precision et Recall, utile quand on veut un seul chiffre résumant le compromis entre les deux :

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

*Pourquoi une moyenne harmonique et pas arithmétique ?* Elle pénalise fortement le déséquilibre : si Precision = 1 et Recall = 0, la moyenne arithmétique donnerait 0.5 (trompeur), alors que le F1 donne 0 (reflète bien qu'un des deux aspects est totalement raté).

**ROC-AUC.** La courbe ROC trace le taux de vrais positifs ( $\text{Recall} = TP/(TP+FN)$ ) contre le taux de faux positifs ( $FPR = FP/(FP+TN)$ ) pour *tous les seuils de décision possibles* (pas seulement 0,5). L'AUC (*Area Under the Curve*) résume cette courbe en un seul nombre entre 0 et 1 :

- AUC = 1 : séparation parfaite entre les deux classes.
- AUC = 0.5 : le modèle n'est pas meilleur qu'un tirage aléatoire.

*Intérêt par rapport à Accuracy/Precision/Recall* : l'AUC évalue le modèle indépendamment du choix d'un seuil précis — utile pour comparer des modèles avant de décider où placer le seuil de décision selon le contexte métier.

### 3.3 Régression — Métriques

**MAE (Mean Absolute Error)** — moyenne des erreurs en valeur absolue, dans la même unité que le target (facile à interpréter) :

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$

**MSE (Mean Squared Error)** — moyenne des erreurs au carré (pénalise fortement les grosses erreurs, cf. section Linear Regression pour la justification du carré) :

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

**RMSE (Root Mean Squared Error)** — racine carrée du MSE, ce qui la ramène dans la *même unité* que le target (contrairement au MSE) tout en gardant la pénalisation forte des grandes erreurs :

$$\text{RMSE} = \sqrt{\text{MSE}}$$

**$R^2$  (coefficient de détermination)** — proportion de la variance du target expliquée par le modèle, comparée à un modèle "naïf" qui prédirait toujours la moyenne  $\bar{y}$  :

$$R^2 = 1 - \frac{\sum_{i=1}^m (y_i - \hat{y}_i)^2}{\sum_{i=1}^m (y_i - \bar{y})^2}$$

- $R^2 = 1$  : le modèle prédit parfaitement.
- $R^2 = 0$  : le modèle ne fait pas mieux que prédire la moyenne.
- $R^2 < 0$  : le modèle fait *pire* que la moyenne (possible sur un test set, signe d'un modèle mal ajusté).

### 3.4 Questions types

**Precision vs Recall — quand privilégier laquelle ?** Le choix dépend du coût relatif d'un FP par rapport à un FN :

- **Privilégier Precision** quand un FP coûte cher (fausse alerte coûteuse à traiter) — ex. mobiliser une équipe portuaire pour un retard qui n'arrive finalement pas.

- **Privilégier Recall** quand un FN coûte cher (rater un cas positif est grave) — ex. ne pas détecter un navire réellement en retard et donc ne pas anticiper l'engorgement du quai.

Il y a toujours un compromis : augmenter le seuil de décision augmente la Precision mais baisse le Recall, et inversement — d'où l'intérêt du F1-score ou de l'AUC pour arbitrer.

**Qu'est-ce que l'overfitting ?** Le modèle apprend "par cœur" les particularités (et le bruit) des données d'entraînement au lieu d'apprendre la tendance générale — il obtient une excellente performance sur le train set mais une performance nettement plus faible sur des données jamais vues (test set). L'inverse, l'*underfitting*, correspond à un modèle trop simple qui ne capte même pas la tendance générale (mauvaise performance sur train *et* test).

**Comment le détecter ?** Comparer la performance sur le train set et sur le test/validation set : un grand écart (très bon sur train, nettement moins bon sur test) est le signe caractéristique de l'overfitting.

**Comment le réduire ?**

- Plus de données d'entraînement (si possible).
- Régularisation (L1/L2 pour les modèles linéaires ;  $\gamma, \lambda$  pour XGBoost ; profondeur maximale/nombre minimal d'observations par feuille pour les arbres).
- Réduire la complexité du modèle (moins de features, arbre moins profond, moins d'arbres).
- Cross-validation pour détecter l'overfitting de façon fiable pendant le choix des hyperparamètres.
- Early stopping (arrêter l'entraînement dès que la performance sur validation cesse de s'améliorer, utile pour XGBoost et le boosting en général).
- Dropout/data augmentation (plutôt côté Deep Learning, à mentionner si la question dérive vers les réseaux de neurones).

## 4 ML avancé (Jour 3)

### 4.1 Preprocessing

### 4.2 Feature engineering et feature selection

### 4.3 Data leakage

### 4.4 Imbalanced dataset et SMOTE

### 4.5 Cross-validation

### 4.6 Hyperparameter tuning

### 4.7 Gradient Boosting et Ensemble Learning

### 4.8 Questions ouvertes