

Statistiques — Fiche de révision

Concours ANP — Cadre Data Scientist

1 Moyenne, médiane

1.1 Moyenne (arithmétique)

La **moyenne** est la somme des valeurs divisée par leur nombre :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Sensible aux **valeurs extrêmes** (outliers) : un seul salaire très élevé peut tirer la moyenne vers le haut.
- Utilise toute l'information disponible (contrairement à la médiane).

1.2 Médiane

La **médiane** est la valeur qui sépare la série ordonnée en deux moitiés égales (50% en dessous, 50% au-dessus).

- n impair : valeur centrale après tri.
- n pair : moyenne des deux valeurs centrales.
- **Robuste aux outliers** : ne dépend pas de l'amplitude des valeurs extrêmes, seulement de leur rang.

1.3 Quand utiliser laquelle ?

- Distribution symétrique, sans outliers → moyenne (ex. tailles).
- Distribution asymétrique ou avec outliers → médiane (ex. salaires, prix immobiliers, temps d'attente des navires).
- Si moyenne $\gg$ médiane : distribution étalée vers la droite (quelques très grandes valeurs).

2 Variance et écart-type

2.1 Variance

La **variance** mesure la dispersion des valeurs autour de la moyenne :

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (\text{population}) \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (\text{échantillon})$$

- Toujours ≥ 0 .
- Exprimée dans le **carré** de l'unité d'origine (ex. euros²), donc difficile à interpréter directement.
- Diviser par $n-1$ (correction de Bessel) au lieu de n pour un échantillon corrige le biais d'estimation.

2.2 Écart-type

L'**écart-type** est la racine carrée de la variance :

$$\sigma = \sqrt{\sigma^2}$$

- Même unité que les données d'origine → plus interprétable que la variance.
- Écart-type faible = valeurs concentrées autour de la moyenne ; écart-type élevé = valeurs dispersées.

3 Covariance et corrélation

3.1 Covariance

La **covariance** mesure si deux variables varient ensemble (dans le même sens ou en sens opposé) :

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- $\text{Cov} > 0$: X et Y évoluent dans le même sens.
- $\text{Cov} < 0$: X et Y évoluent en sens opposés.
- $\text{Cov} \approx 0$: pas de relation linéaire apparente.
- Problème : l'échelle dépend des unités, donc difficile de comparer deux paires de variables entre elles.

3.2 Corrélation (coefficient de Pearson)

La **corrélation** normalise la covariance pour la rendre comparable, sans unité :

$$r = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}, \quad r \in [-1, 1]$$

- $r = 1$: corrélation linéaire positive parfaite.
- $r = -1$: corrélation linéaire négative parfaite.
- $r = 0$: pas de relation **linéaire** (mais une relation non-linéaire peut exister).
- **Corrélation n'implique pas causalité** — question piège classique en entretien.

4 Distribution normale

La **loi normale** (gaussienne) est une distribution continue, symétrique, en forme de cloche, définie par deux paramètres : la moyenne μ et l'écart-type σ .

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

4.1 Propriétés clés

- Symétrique autour de μ : moyenne = médiane = mode.
- **Règle 68–95–99,7** :
 - 68% des valeurs dans $[\mu - \sigma, \mu + \sigma]$
 - 95% des valeurs dans $[\mu - 2\sigma, \mu + 2\sigma]$
 - 99,7% des valeurs dans $[\mu - 3\sigma, \mu + 3\sigma]$
- Sert de base à de nombreux tests statistiques et à la détection d'outliers (au-delà de 3σ).

5 Probabilités

5.1 Notions de base

- Une **probabilité** $P(A)$ mesure la chance qu'un événement A se réalise, $P(A) \in [0, 1]$.
- $P(\Omega) = 1$ (univers des possibles), $P(\emptyset) = 0$.
- Événements **indépendants** : $P(A \cap B) = P(A) \times P(B)$.
- Événements **incompatibles** (disjoints) : $P(A \cup B) = P(A) + P(B)$.
- Cas général : $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

5.2 Probabilité conditionnelle

La **probabilité conditionnelle** $P(A | B)$ est la probabilité que A se réalise sachant que B est déjà réalisé :

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

- Si A et B sont indépendants : $P(A | B) = P(A)$ (connaître B n'apporte aucune information sur A).
- Exemple portuaire : probabilité qu'un navire soit en retard sachant qu'il y a une tempête.

6 Théorème de Bayes

Le **théorème de Bayes** permet d'inverser une probabilité conditionnelle, c'est-à-dire de déduire $P(A | B)$ à partir de $P(B | A)$:

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}$$

6.1 Lecture des termes

- $P(A)$: probabilité **a priori** de A (avant observation).
- $P(A | B)$: probabilité **a posteriori** de A (après avoir observé B).
- $P(B | A)$: vraisemblance (*likelihood*) de B sachant A .
- $P(B)$: probabilité marginale de B (constante de normalisation).

6.2 Exemple classique (test médical / détection de fraude)

Un test de détection est positif à 99% chez les cas réels (vraisemblance), mais la maladie/fraude ne touche que 1% de la population (a priori). Le théorème de Bayes montre que, malgré un test fiable à 99%, la probabilité qu'un résultat positif soit un vrai cas reste souvent faible si l'événement est rare

- d'où l'importance de ne pas confondre $P(B | A)$ et $P(A | B)$.

6.3 Lien avec le Machine Learning

- Base du classifieur **Naive Bayes** (hypothèse d'indépendance des features).
- Fondement du raisonnement bayésien : mise à jour d'une croyance (a priori) à mesure que de nouvelles données (évidence) arrivent.

7 Questions types (révision active)

1. Quelle est la différence entre moyenne et médiane ? Quand préférer l'une à l'autre ?
2. Pourquoi diviser par $n - 1$ et non n pour la variance d'un échantillon ?
3. Quelle est la différence entre covariance et corrélation ?
4. Une corrélation de 0,9 entre deux variables implique-t-elle une causalité ?
5. Que signifie la règle 68-95-99,7 pour une loi normale ?
6. Donnez un exemple de probabilité conditionnelle dans le contexte portuaire.

7. Énoncez le théorème de Bayes et expliquez la différence entre a priori et a posteriori.

8 Corrigé des questions types

Q1. Différence moyenne / médiane, quand préférer l'une à l'autre ?

La moyenne additionne toutes les valeurs et divise par leur nombre — elle utilise toute l'information mais est tirée par les valeurs extrêmes. La médiane est la valeur centrale d'une série triée — elle ignore l'amplitude des extrêmes, seulement leur rang. On préfère la médiane quand la distribution est asymétrique ou contient des outliers (salaires, prix immobiliers, temps d'attente des navires) ; la moyenne convient pour des distributions symétriques sans valeurs aberrantes.

Q2. Pourquoi diviser par $n - 1$ et non n pour la variance d'un échantillon ?

Parce qu'on utilise la moyenne de l'échantillon $\bar{x}$ (elle-même estimée à partir des données) plutôt que la vraie moyenne de la population μ . Cela introduit un léger biais qui sous-estime systématiquement la variance réelle. Diviser par $n - 1$ (correction de Bessel) compense ce biais et donne un estimateur non biaisé. Avec la vraie moyenne de population connue, diviser par n serait correct — d'où la distinction population (n) vs échantillon ($n - 1$).

Q3. Différence covariance / corrélation ?

Les deux mesurent si deux variables varient ensemble. La covariance dépend des unités des variables (ex. euros $\times$ kg), donc son échelle n'est pas interprétable ni comparable entre paires de variables. La corrélation normalise la covariance en la divisant par le produit des écarts-types, ce qui donne toujours une valeur entre -1 et 1 , sans unité, donc comparable et interprétable directement.

Q4. Une corrélation de 0,9 implique-t-elle une causalité ?

Non. **Corrélation n'implique pas causalité.** Une forte corrélation peut venir d'une vraie relation causale, mais aussi d'une variable confondante commune, d'une coïncidence statistique, ou d'une causalité inverse (B cause A plutôt que A cause B). Exemple classique : les ventes de glaces et les noyades sont corrélées, mais la cause commune est la chaleur estivale, pas un lien direct entre les deux.

Q5. Que signifie la règle 68-95-99,7 pour une loi normale ?

Pour une distribution normale de moyenne μ et écart-type σ : environ 68% des valeurs se situent dans $[\mu - \sigma, \mu + \sigma]$, 95% dans $[\mu - 2\sigma, \mu + 2\sigma]$, et 99,7% dans $[\mu - 3\sigma, \mu + 3\sigma]$. C'est ce qui justifie la détection d'outliers au-delà de 3 écarts-types : une valeur si éloignée a moins de 0,3% de chance d'appartenir à la distribution normale.

Q6. Exemple de probabilité conditionnelle dans le contexte portuaire ?

$P(\text{retard} \mid \text{tempête})$: la probabilité qu'un navire soit en retard sachant qu'il y a une tempête. Elle sera bien plus élevée que $P(\text{retard})$ pris isolément (probabilité de retard tous cas confondus), car la tempête est une information qui change l'estimation du risque de retard.

Q7. Théorème de Bayes : a priori vs a posteriori ?

$$P(A \mid B) = \frac{P(B \mid A) P(A)}{P(B)}$$

$P(A)$ est la probabilité **a priori** : ce qu'on croit avant d'observer une nouvelle donnée B . $P(A \mid B)$ est la probabilité **a posteriori** : la croyance mise à jour après avoir observé B . $P(B \mid A)$ est la vraisemblance (à quel point B est probable si A est vrai). Le théorème de Bayes formalise la mise à jour d'une croyance à la lumière d'une nouvelle évidence — c'est le principe même du raisonnement bayésien et la base du classifieur Naive Bayes.